

VAE

송용호

PDF 정의

$$p_{\theta}(x) = \int p_{\theta}(z)p_{\theta}(x|z)dz$$

X는 iid, 동일 분포 따른다고 가정

세타는 파라미터

세타가 주어졌을 때, x가 나올 확률

이걸 최대화 하는게 목표.

Latent 변수 Z를 사용해서 나타내면 위 식과 같음.

이거 미분해서 SGD 할거임.

근데 z에서 샘플링하는거잖


분포는 가우시안이나 베르누이로 설정(다루기 쉬워서)

근데 모든 z에 대해 적분해야해 -> 못해

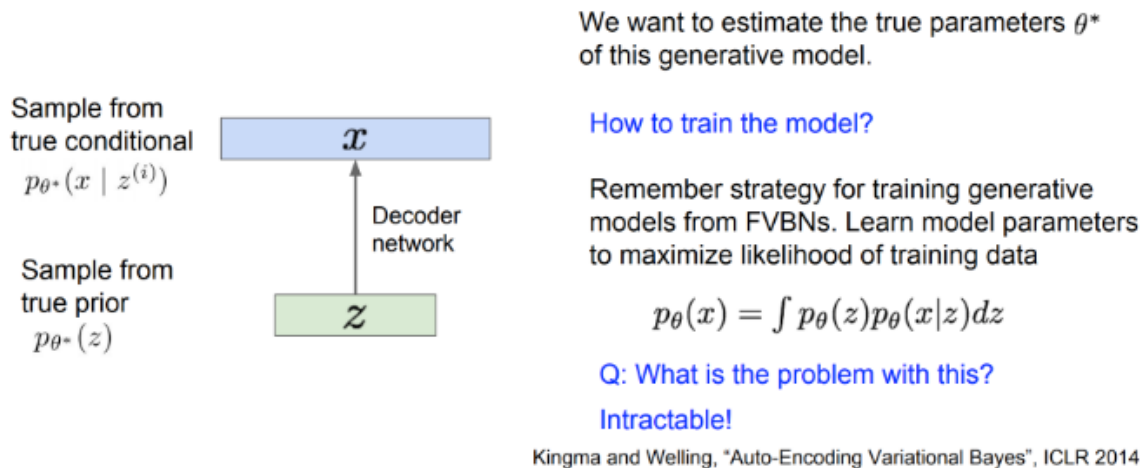
근데 MLE 문제를 풀려면 미분 해야해

이걸론 못함.

Latent variable



문제 2개



2. 적분을 어떻게 해결?

이거 다 계산 하 말고 Monte-Carlo estimation으로 하자.

근데 대부분 0값 가지니까, 많이 해야해.

가뜰이나 딥러닝 오래 걸리는데 많이 할 여유 없음

데이터에 종속적으로 z 를 샘플링하자.(2)

1. Z변수를 어떻게 구성?

가우시안 분포로부터 샘플링함
디코더는 z 로 부터 데이터 생성

여러층의 레이어가 있으면

앞층은 Normal을 latent로 바꿔주고

뒤에는 이거 가지고 sampling 할 수 있는 pdf를 만들어내는것.

$$p_{\theta}(x) = \int p_{\theta}(z)p_{\theta}(x|z)dz \approx \frac{1}{N} \sum_{i=1}^N p_{\theta}(x|z^{(i)}) \quad (2)$$

새로운 함수 정의

$$p_{\theta}(x) = \int p_{\theta}(z)p_{\theta}(x|z)dz \approx \frac{1}{N} \sum_{i=1}^N p_{\theta}(x|z^{(i)}) \quad (2)$$

Posterior density also intractable: $p_{\theta}(z|x) = p_{\theta}(x|z)p_{\theta}(z)/p_{\theta}(x)$

Intractable data likelihood

그래서 z given x 를 생각해보자 이거야.

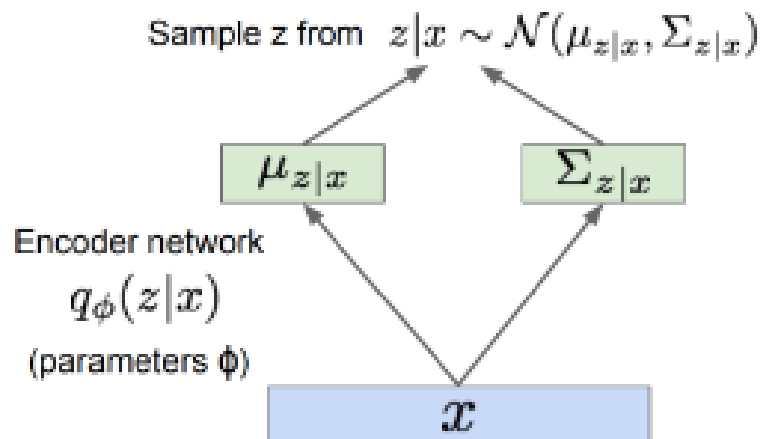
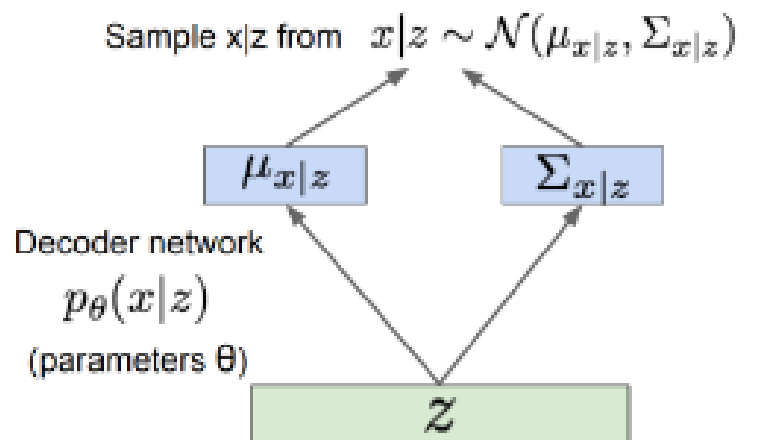
근데 x 는 추적 불가능하잖

그니까 저 빨간 저것도 계산이 안돼

그래서 approximate하는 새로운 함수를 정의

$$q_{\phi}(z|x)$$

새로운 함수 정의2



$q_{\phi}(z|x)$ 요건 원래 posterior를 근사했기 때문에 오류 존재
따라서 Object function에 lower bound 정의 할거임.
그 전에 VAE 구조부터 봐보자.

1. x 받아서 latent에 분포 만듦
2. 가우시안이라 가정하고, data dependent한 가우시안 분포로부터 z 샘플링
3. 샘플링된 z 가지고 다시 가정한 분포로 디코더가 분포를 뱉어냄
4. x 를 이 분포로부터 샘플링.

ELBO(Evidence Lower Bound)

<https://velog.io/@thdfydgh/ELBO>

$$\begin{aligned}
 \log p_{\theta}(x^{(i)}) &= \mathbf{E}_{z \sim q_{\phi}(z|x^{(i)})} [\log p_{\theta}(x^{(i)})] && (p_{\theta}(x^{(i)}) \text{ Does not depend on } z) \\
 &= \mathbf{E}_z \left[\log \frac{p_{\theta}(x^{(i)} | z) p_{\theta}(z)}{p_{\theta}(z | x^{(i)})} \right] && (\text{Bayes' Rule}) \\
 \text{Reconstruct the input data} &= \mathbf{E}_z \left[\log \frac{p_{\theta}(x^{(i)} | z) p_{\theta}(z) q_{\phi}(z | x^{(i)})}{p_{\theta}(z | x^{(i)}) q_{\phi}(z | x^{(i)})} \right] && (\text{Multiply by constant}) \\
 &= \mathbf{E}_z \left[\log p_{\theta}(x^{(i)} | z) \right] - \mathbf{E}_z \left[\log \frac{q_{\phi}(z | x^{(i)})}{p_{\theta}(z)} \right] + \mathbf{E}_z \left[\log \frac{q_{\phi}(z | x^{(i)})}{p_{\theta}(z | x^{(i)})} \right] && (\text{Logarithms}) \\
 &= \underbrace{\mathbf{E}_z [\log p_{\theta}(x^{(i)} | z)]}_{\mathcal{L}(x^{(i)}, \theta, \phi)} - \underbrace{D_{KL}(q_{\phi}(z | x^{(i)}) || p_{\theta}(z))}_{> 0} + \underbrace{D_{KL}(q_{\phi}(z | x^{(i)}) || p_{\theta}(z | x^{(i)}))}_{> 0}
 \end{aligned}$$

Make approximate posterior distribution close to prior

$\log p_{\theta}(x^{(i)}) \geq \mathcal{L}(x^{(i)}, \theta, \phi)$
 Variational lower bound ("ELBO")

$\theta^*, \phi^* = \arg \max_{\theta, \phi} \sum_{i=1}^N \mathcal{L}(x^{(i)}, \theta, \phi)$
 Training: Maximize lower bound

의미 :

1항 : q의 x로부터 sample한 z가 있음.
 z가지고 p가 x를 생성할 likelihood

2항 : prior인 z와 approximate된 q 사이의 KLD

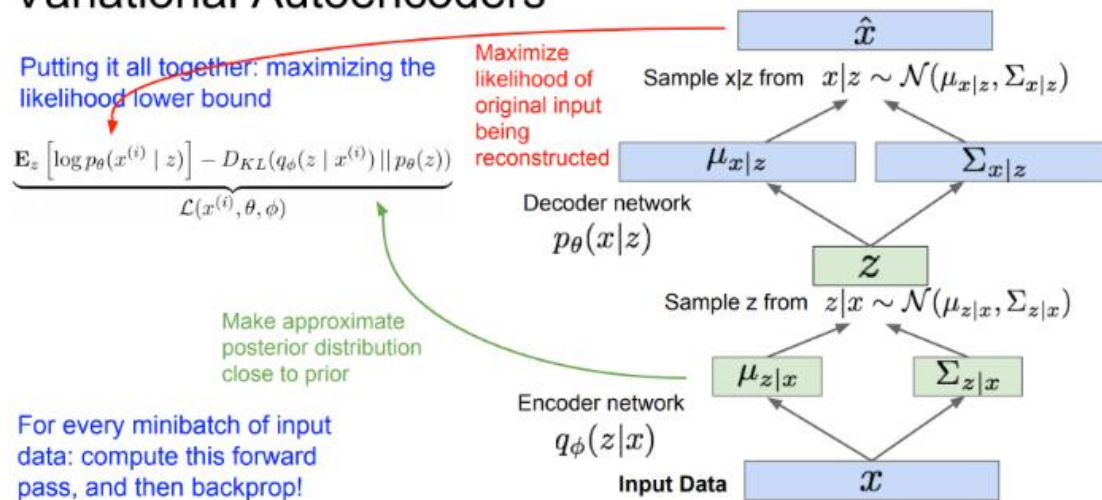
3항 : z given x는 추적 불가능, 상수취급

1,2항만 가지고 하한 설정 가능,

미분 가능해짐, MLE를 위해 backpropa 가능

train

Variational Autoencoders



X를 넣으면, latent space상의 mean, var 뽑음
: dim당 하나씩

그럼 mean과 var이 posterior를 나타내게 됨.

그럼 prior과 KLD를 구할 수 있어.

Z로부터 decoder는 data space상의 mean과 var을 뽑아

그럼 ELBO 1항(recon) 구할 수 있음

Backprop하면 VAE 학습 완료.

Monte carlo estimation

$$\mathcal{L}(x^{(i)}, \theta, \phi) = \mathbb{E}_z[\log p_\theta(x^{(i)}|z)] - D_{KL}(q_\phi(z|x^{(i)})||p_\theta(z))$$

$$\nabla_\phi \mathbb{E}_{q_\phi(z)}[f(z)] = \int \nabla_\phi q_\phi(z) f(z) dz$$

$$= \int q_\phi(z) \frac{\nabla_\phi q_\phi(z)}{q_\phi(z)} f(z) dz$$

$$= \mathbb{E}_{q_\phi(z)}[f(z) \nabla_\phi \log q_\phi(z)]$$

근데 1항에 파이에 대해 미분하는건 문제가 있음

ϕ 에 대해서 미분하는 것은 문제가 있습니다. 그 이유는 첫 번째 항인 $\mathbb{E}_{z \sim q_\phi(z|x)}[\log p_\theta(x|z)]$ 의 기댓값을 구하기 위해서는, $\mathbb{E}_{q_\phi(z|x)}$ 의 형태로 되어 있어야 합니다. 그러나 $\log p_\theta(x|z)$ 의 기댓값을 구하기 위해서는 z 를 $q_\phi(z|x)$ 로부터 샘플링해야 합니다. 이러한 샘플링 과정에서는 그라디언트가 ϕ 에 대해 직접적으로 전달되지 않습니다. 따라서 미분이 어려워집니다.

근데 1항에 파이에 대해 미분하는건 문제가 있음


그래서 Monte carlo estimation을 사용

Sample해서 평균 때리잔건데,

그냥 1번 뽑는걸로 통 침.(여기서 $L=1$)

$$\frac{1}{L} \sum_{l=1}^L f(z^{(l)}) \nabla_\phi \log q_\phi(z^{(l)})$$

Reparameterization trick

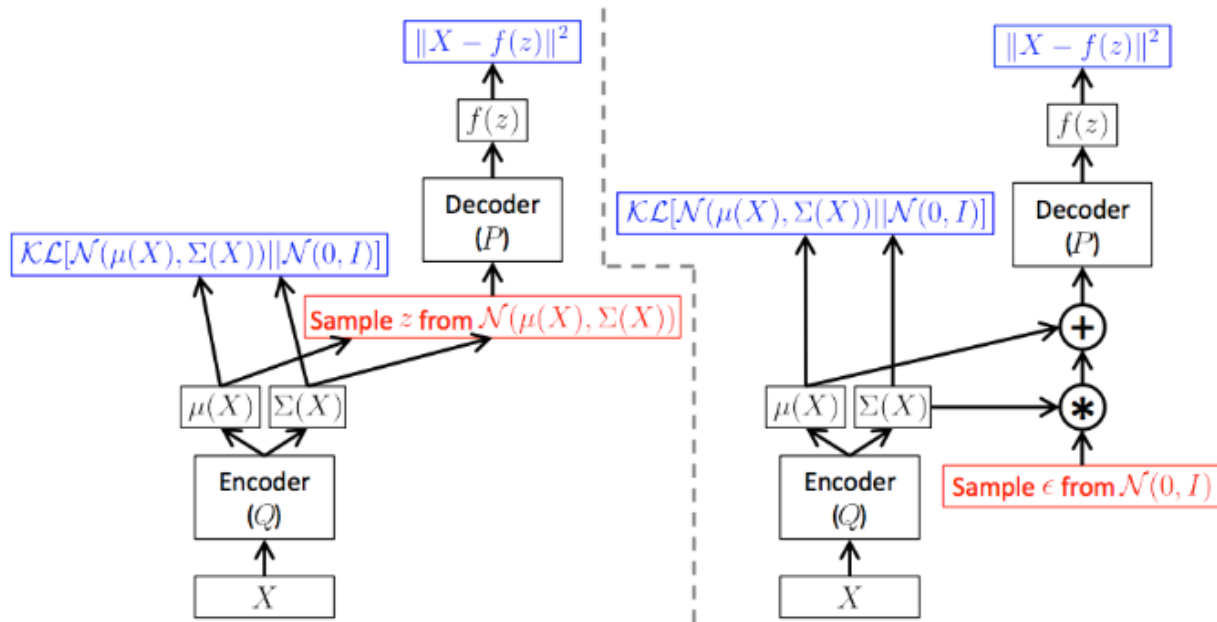


근데 몬테 카를로는 분산이 너무 커서 gradient 전달이 안됨.

그래서 reparm trick을 사용.

다들 알거라 생각하고 skip

Auto Encoding Variational Bayes



reparameterization trick을 그림으로 보자면

encoder로부터 구한 data dependent한 mean과 variance를 가지고 posterior를 만듦

그 posterior로부터 z를 샘플링한 다음에 그 z를 가지고 decoder는 data를 generation

하지만 reparameterization을 하면

computation graph 내의 sampling 과정이

noise sampling이 되어 옆으로 빠져

따라서 Back propagation을 통해 decoder output으로부터 encoder까지 gradient가 전달

Algorithm 1 Minibatch version of the Auto-Encoding VB (AEVB) algorithm. Either of the two SGVB estimators in section 2.3 can be used. We use settings $M = 100$ and $L = 1$ in experiments.

$\theta, \phi \leftarrow$ Initialize parameters

repeat

$\mathbf{X}^M \leftarrow$ Random minibatch of M datapoints (drawn from full dataset)

$\epsilon \leftarrow$ Random samples from noise distribution $p(\epsilon)$

$\mathbf{g} \leftarrow \nabla_{\theta, \phi} \tilde{\mathcal{L}}^M(\theta, \phi; \mathbf{X}^M, \epsilon)$ (Gradients of minibatch estimator (8))

$\theta, \phi \leftarrow$ Update parameters using gradients \mathbf{g} (e.g. SGD or Adagrad [DHS10])

until convergence of parameters (θ, ϕ)

return θ, ϕ
